

Recomendación a conjuntos de usuarios, basada en grupos heterogéneos con características similares

Diego Cartagena Herrera

Pontificia Universidad Católica de Chile Pontificia Universidad Católica de Chile Pontificia Universidad Católica de Chile

Santiago, Chile

dcartagena@uc.cl

Benjamín Huerfano Zapata

Santiago, Chile

bahuerfano@uc.cl

Jasiel Toscano Martínez

Santiago, Chile

jhtoscano@uc.cl

Abstract—Los sistemas de recomendación grupal se han convertido en un tema de interés para la comunidad científica enfocada en área de los sistemas de recomendación debido a que los seres humanos somos de una naturaleza social, es decir, las personas con frecuencia participan en actividades grupales, como observar una película en familia o planificar un viaje de vacaciones en compañía. En la actualidad, los algoritmos de recomendación para usuarios no son tan eficientes para realizar recomendaciones a un conjunto de personas, por lo que se requieren técnicas efectivas para abordar el tema de recomendaciones grupales. En esta investigación se propone un modelo para efectuar recomendaciones a un conjunto de personas con base en grupos heterogéneos con características similares, es decir, recomendaciones a un grupo de personas definidas mediante un algoritmo de agrupación, que serán clasificadas por algún atributo o característica. Las líneas de base usadas son los métodos sobre ratings (SlopeOne, userKnn, itemKnn, Funk SVD), información implícita (ALS-Alternating Least Squares, BPR-Bayesian Personalised Ranking) y el manejo de las relaciones con grafos (CSE-Collaborative Similarity Embedding). Los resultados que se obtuvieron a través del modelo muestran que, si bien estos sistemas no están enfocados en realizar recomendaciones grupales, obtienen en cierto grado resultados favorables al generar incrustaciones de similitud colaborativa usando el marco de referencia CSE.

Index Terms—Sistemas Recomendadores, Recomendación grupal, SlopeOne, Item kNN, User kNN, FunkSVD, ALS, BPR, CSE.

I. INTRODUCCIÓN

Los sistemas de recomendación tradicionales se han convertido en una importante herramienta para las personas debido a que proporcionan elementos de información con base en sus preferencias y características. Sin embargo, existen contextos en donde los enfoques tradicionales no realizan de manera eficiente su función debido a que las personas realizan actividades en conjunto, por lo que se requieren técnicas efectivas para abordar el tema de la recomendación a un grupo de personas. En los últimos años, los sistemas de recomendación grupal se han convertido en objeto de intensa investigación para la comunidad científica, en especial, para la comunidad enfocada en los sistemas de recomendación debido a la que las personas suelen realizar actividades en conjunto, como asistir a los conciertos en compañía de amigos, planificar un viaje vacacional grupal, observar una película en familia, entre otras. El principal desafío de los sistemas de recomendación grupal consiste en intentar satisfacer a la mayoría de las

personas que forman del grupo, debido a que cada una de las personas tienen diferentes opiniones en relación a los mismos elementos. En esta investigación se propone un modelo para efectuar recomendaciones a un conjunto de personas con base en grupos heterogéneos con características similares, es decir, recomendaciones a un grupo de personas definidas mediante un algoritmo de agrupación, que serán clasificadas por algún atributo o característica.

II. ESTADO DEL ARTE

En la actualidad, la comunidad científica enfocada en el tema de los sistemas de recomendación han comenzado el estudio del comportamiento grupal para abordar el tema de las recomendaciones a un grupo de personas. Por ejemplo, Tran et al. (2019) [12] propone modelar las interacciones entre miembros del grupo a través de una arquitectura neuronal denominada Mezcla de Redes de subatención (Medley of Sub-attention Networks, MoSAN). Esta arquitectura es una variante del mecanismo de atención, en donde cada miembro se representa con una única red de sub-atención. Posteriormente, un grupo de usuarios se representa como una mezcla de redes de su-batención, encargada de realizar la recomendación general. La tarea de cada red de subatención se basa en capturar la preferencia de su miembro representativo del grupo en relación a todos los demás miembros del grupo. La arquitectura aprovecha las interacciones usuario-usuario para la recomendación grupal. En Cao et al, 2018 [13] se aborda el problema de la agregación de las preferencias proponiendo una solución denominada recomendación grupal atenta (Attentive group recommendation, AGRee), basada en una red de atención y en un filtrado colaborativo neuronal. Esta red de atención se utiliza para formar la representación de un grupo agregando integraciones de los miembros, permitiendo aprender pesos de atención de los miembros. El filtrado colaborativo neuronal es utilizado para aprender interacciones elemento-usuario y elemento-grupo en el mismo espacio de integración. A diferencia del trabajo anterior, Cao et al, 2019 [14] propone considerar al mismo tiempo la influencia del miembro y la información de seguidores sociales, que se incorpora a través de otra red de atención para mejorar la representación del usuario, lo que resulta ser beneficio para comprender preferencias personales. Hu et al, 2014 [?] se propone un modelo de arquitectura profunda, en donde se usan

características de alto nivel derivadas de características de bajo nivel para representar preferencias grupales. Este modelo se construye a partir de redes colectivas de creencias profundas y máquina restringida de Boltzmann. La máquina se diseña en el nivel superior para aprender la representación de las preferencias del grupo mediante el modelado conjunto de las opciones grupales y las características colectivas. Entre los diferentes problemas a los que se enfrentan los sistemas de recomendación grupal, se encuentra el modelado de las preferencias grupales, donde diversos trabajos centran su interés en el modelado de las interacciones entre los miembros del grupo [1]. Sin embargo, a pesar de los avances este tema sigue siendo un tema de investigación abierto debido a la complejidad que representa realizar con éxito el modelado de dichas interacciones.

III. METODOLOGÍA

En esta investigación se propone realizar recomendación de usuarios usando como baselines métodos sobre ratings (SlopeOne, user KNN, item KNN, Funk SVD), información implícita (BPR [7] Y ALS [8]) y manejo de relaciones con grafos (CSE-Collaborative similarity embedding [2]). Los conjunto de datos usados son: MaFengWo y CAMRa2011. Las métricas de evaluación utilizadas son: MSE, DCG@10, MAP@10.

Se planteó la forma de implementar métodos de interacción entre usuarios con información de grupos para evaluar su eficacia y brindar un punto de evaluación de los método CSE, para ello se implementó la creación de una columna de calificación basado en lo expuesto la sección resultados. a partir Datasets MaFengWo y CAMRa2011

A. SlopeOne

Se realiza la obtención de los valores posibles dentro de la tabla sparse de los datasets, por medio de una proyección basada en los valores que ha tenido un elemento y los ratings que le usuario en cuestión, realiza la búsqueda de k usuarios y se predicen los items sin interacción del dataset para un usuario u_i [4].

B. User KNN e Item KNN

Se realiza la separación de k usuarios o items (K-Nearest-Neighbor) más cercanos al objeto en cuestión, en cuanto a valoraciones o participación de un usuario o item, a si pues las similitudes se darán en a lo largo del dataset y dependiendo del parecido con las calificaciones o interacciones con los objetos se define una lista de posibles recomendaciones.

C. Funk SVD

Aprovecha la descomposición por valores singulares para realizar un $USV^T = \sum_{i=1}^n s_i \sigma_i v_i^T$, para obtener vectores de caracterización de las interacciones y los usuarios, estos datos se obtienen el hiper-parametros de los factores latentes sobre los cuales se puede ajustar el modelo El método de predicción de calificación extrapolable directamente a la recomendación basada en calificación (colaborativo), bajo premisas de uso

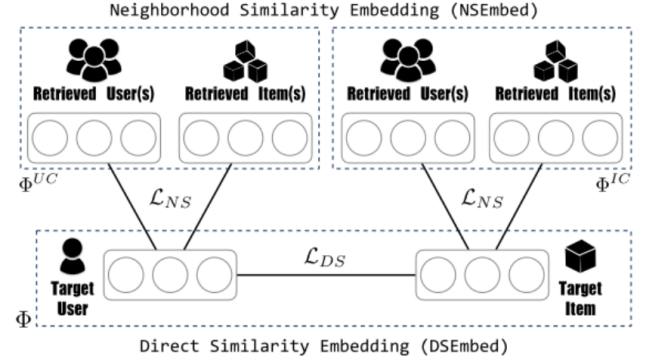


Fig. 1. Arquitectura CSE manejo de 3 set Interacciones a) User-User b) Item-Item c) Usuario-Item [3].

de ratings promedios y eliminación de información poco relevante bajo una premisa de entrenamiento auto gestionado y automatizado, permitiendo la generación de un algoritmo eficiente y con un nivel de complejidad inusualmente "bajo" [9].

D. ALS-Alternating Least Squares

Este algoritmo realiza la factorización de una matriz R dada en dos factores U y V tal que $R = U^T V$. La fila desconocida es proporcionada como parámetro del algoritmo denominada como factores latentes. Las matrices U y V se denominan matriz de usuario y de elemento. La i th columna de la matriz de elemento es denotada por u_i y la i th columna del elemento es representando v_i . La matriz R se denominada matriz de calificaciones con $(R)_{i,j} = r_{i,j}$ [8].

E. BPR-Bayesian Personalized Ranking

Este método está en función del supuesto que un usuario prefiere un elemento consumido en lugar de un artículo no consumido. La entrada de este método consiste en una matriz de calificación usuario-elemento, en donde se capturan solamente las interacciones positivas denominada retroalimentación unaria, es decir, un usuario i interactúa con un el elemento j . Este método utiliza las preferencias por pares derivadas de las calificaciones implícitas para optimizar un criterio de clasificación [7] [11].

F. CSE - Collaborative similarity embedding [2]

Es un método diseñado para obtener información a partir de un grafo de interacciones G con nodos de usuarios e items y conexiones de valor ("ratings"), por medio de optimización y basados en el algoritmo de búsqueda Random Walk (el cual busca a cierta distancias y pasos de un grafo [5]), se realiza la abstracción de los vectores de embeddings. Este método se generan L cantidad de Embeddings bajo la minimización de función de perdida dadas por la probabilidad de uso de un elemento por un usuario (o item), su arquitectura se basa en lo expuesto en la figura 1.

Esta arquitectura implementa 3 subsets de datos (interacciones usuario-item, usuario-usuario e item-item) obtenidos

por Random Walk [5] y el grafo G , que le permite ir a nodos conectados en diferentes ordenes, lo cual asegura obtener relación de información de múltiples niveles y relaciones de los datos además conexiones.

IV. DATASETS

La presente sección se realizó el cambio de Dataset respecto al de cervezas (BeerReviews) con el cual contábamos inicialmente (bajo recomendación del docente Dennis Parra) para lo cual se obtuvo información de 2 datasets (MaFengWo y CAMRa2011), los cuales tienen interacciones y relaciones entre grupos de usuarios, pese a que no se cuenta con el dataset original se obtuvo segmentación de datos adecuada para el trabajo de recomendación a grupos e individuos.

A. MaFengWo

Es un dataset obtenido de información obtenida a través portal web de turismo donde los usuarios pueden registrar sus lugares de viaje. La información explícita del dataset es poca debido a que solo cuenta con datos de ID_Usuario/Grupo y lugar visitado., pero respecto al ámbito de grupos y análisis social permite contiene los usuarios pertenecientes a los grupos y datos sociales como seguimiento a usuarios de interés (follow data), pese, a que no se cuenta con el dataset original la información es más que suficiente para implementar técnicas de recomendación (datos que se extrañaran son el timestamp, rating y reviews).

1) *Análisis de datos*: la selección de grupos se realizó teniendo en cuenta que mínimo deben contar con 2 usuarios y 3 viajes realizados, con el fin de capturar grupos y personas con cierto nivel de interacción (acortando la long tail del data set). Se cuenta con una totalidad de 3595 grupos con un promedio de 7.19 usuarios por cada uno y una media de 3.61 viajes por grupo. Respecto al análisis de sitios se identifica una gran de afluencia en los 30 primeros ítems del dataset (ordenado por relevancia de visitas), posteriormente decaen hasta obtener valores de entre 1 y 5 visitas al lugar. conteniendo una “long tail” bastante notoria, debido a sitios muy populares y de fácil acceso.

TABLE I
TABLA CARACTERÍSTICAS DATASET MAFENGWO

Datos	Cant.	Sparsity	Ratings	AVG Viajes	AVG Miembros
Grupo	995	99,76%	3595	3,61	7,19
Usuario	5275	99,50%	39761	7,54	N/A
Follows	5275	83,43%	53235	N/A	4,06

Adicional a ello el dataset cuenta con información de seguimiento de usuarios “follow data” los cuales pueden seguir a otro permitiendo identificar relaciones además de posibilidades de interacciones sociales y definición de gustos o posibles preceptos de recomendación, para 5276 usuario se cuenta con los seguidores de estos, 13096 seguidores y 53235 interacciones de seguimiento, en promedio cada Grupo cuenta con 10.09 seguidores, y usuario regularmente es seguido por 4.06 usuarios.

B. CAMRa2011

Este conjunto de datos surge en el desafío sobre recomendación de películas (7710 items) sensibles al contexto, pues la mayoría de los enfoques no integran información contextual, como la hora, la ubicación. A diferencia de base de datos tradicionales, este conjunto contiene una serie de características contextuales para generar recomendaciones sensibles al contexto. En la Tabla 2 se presentan características.

TABLE II
TABLA CARACTERÍSTICAS DATASET CAMRa2011

Datos	Cant.	Sparsity	Ratings	AVG Vistas	AVG Miembros
Grupo	290	93,51%	145068	500,23	2,08
Usuario	602	97,49%	116344	193,26	N/A

RESULTADOS

C. Ajustes de los experimentos

Se realizó la variación de los distintos parámetros para cada método a fin de obtener los mejores resultados un ejemplo de ello sobre la figura 2, métodos implementados por la librería pyReclab [6] e implicit [11].

Los resultados son mostrados en la sección subsecuente, por otra parte debido a que los valores de rating de MaFengWo era inexistentes, fue necesario realizar un calculo para los mismos, La obtención de ratings para MaFengWo, se realizó la valoración de lo sitios visitados (interacción Grupo-Item r_{gi}), usando la popularidad del sitio y las conexiones de seguidores de los miembros del grupo (1er y 2do Grado), a fin de obtener un rating de 0 a 5. así pues el rating estaría dado por:

$$r_{ti} = \frac{5}{3} \left(\frac{v_i}{\max(V)} + \frac{\sum_{k=1}^{\|g_t\|} foll(u_k)}{\max(follow(G))} + \frac{\sum_{k=1}^{\|g_t\|} foll2(u_k)}{\max(foll2(G))} \right)$$

Donde v_i es el número de veces que a sido visitado el item i , V es el conjunto de todas las visitas a cada lugar $v_i \in V$, la

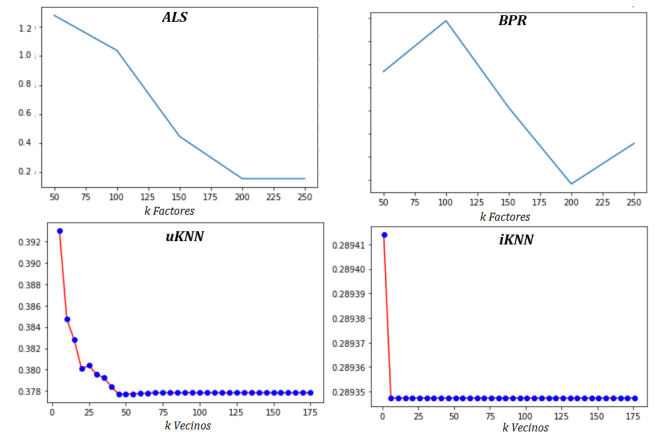


Fig. 2. Resultados RMSE para variaciones de parámetros a) ALS b) BPR c) uKnn d) iKnn

TABLE III
TABLA DE RESULTADOS PARA DATASET MAFENGWO

	ALS	BPR	item KNN	user KNN	Slope One	Funk SVD	CSE
RMSE	-	-	0.38244	0.24766	0.59856	0.20307	1.01983
nDCG@10	0.15176	0.03417	0.95262	0.94523	0.96001	0.98210	0
MAP@10	0.008621	0.035000	0	0	0	0	0.06087

TABLE IV
TABLA DE RESULTADOS PARA DATASET CAMRA2011

	ALS	BPR	item KNN	user KNN	Slope One	Funk SVD	CSE
RMSE	-	-	18.86762	19.32202	67.4929	-	27.45
nDCG@10	0.010345	0.051724	0	0	0	0	1
MAP@10	0.008621	0.035000	0	0	0	0	0.06087

función $foll(...)$ y $foll2(...)$ entrega el numero de seguidores directos e indirectos en segundo grado de un grupo o usuario respectivamente, g_t es un grupo específico t , u_k es un usuario de un grupo, G es el conjunto de todos los grupos $g_t \in G$. Esto asegura que se tendrá en cuenta información de tipo social, grupal y de popularidad de los sitios en el rating.

D. Análisis

En las tablas 1 y 2 se presenta un resumen de los principales resultados para cada uno de los modelos que utilizamos como baseline y del modelo CSE.

Podemos observar que para el dataset MaFengWo (el cual no tenía los rankings realizados por cada grupo), el modelo que obtuvo mayor MAP@10 fue ALS. Por otro lado, el modelo que realizó mejores ranking fue FunkSVD, lo que muestra que los modelos tradicionales de recomendación a usuarios funciona de buena forma. Por otro lado, las recomendaciones hechas al realizar producto punto entre los embeddings de cada grupo con los de items generados por CSE obtuvieron 0 tanto en MAP@10 como nDCG@10. Sin embargo, la métrica RMSE nos indica que los ratings que predijo tiene un error bastante bajo, por lo que este modelo tiene problemas de precisión y ranqueo de recomendaciones.

Por otro lado, el dataset CAMRa2011 obtuvo resultados considerablemente más bajos en todos los modelos tradicionales si se le compara con MaFengWo, donde el RMSE llega a ser del orden de 67 para Slope One. El modelo CSE obtuvo mejores resultados que con MaFengWo, donde nDCG@10 logró el resultado más alto, es decir logró rankear de forma perfecta cada una de las recomendaciones realizadas. Además, obtuvo un 0.06 en MAP@10, por lo que las recomendaciones son más precisas que en MaFengWo.

A partir de lo descrito anteriormente, se puede comenzar a cuestionar el uso de un dataset con información explícita de grupos (como CAMRa2011) para entrenar modelos que fueron destinados para recomendación a usuarios. Por otro lado, el enfoque utilizado para generar los ratings en MaFengWo fue acertado y se ve reflejado al comparar ambos datasets.

CONCLUSIONES

Actualmente los sistemas de recomendación grupal son objeto de una intensa investigación por parte de la comu-

nidad de la comunidad científica debido a la naturaleza de las personas, las cuales realizan diferentes actividades en conjunto. El objetivo de este trabajo consistió en desarrollar un modelo para realizar recomendaciones a un conjunto de personas con base en grupos heterogéneos con características similares, es decir, se efectuaron recomendaciones a un grupo de personas definidas mediante un algoritmo de agrupación, que se clasificaron por un atributo o característica. En este trabajo se utilizaron diversos modelos enfocados en realizar recomendaciones orientadas a usuarios con la finalidad de observar su comportamiento en la recomendación a un conjunto de personas, teniendo en cuenta información adicional de grupos obtenida a través de las bases de datos MaFengWo y CAMRa2011. Los resultados que se obtuvieron muestran resultados favorables al generar incrustaciones usando el marco de trabajo de la incrustación de similitud colaborativa. Las características de información social como seguidores y conexiones entre usuarios, ítem y usuarios ítems, permiten dar una profundidad a los métodos propuestos proporcionando como beneficio computar el contexto de la información.

REFERENCES

- [1] Boratto, L., & Carta, S. (2010). State-of-the-art in group recommendation and new approaches for automatic identification of groups. In Information retrieval and mining in distributed environments (pp. 1-20). Springer, Berlin, Heidelberg.
- [2] Chen, C., Wang, C. J., Tsai, M. F., & Yang, Y. H. (2019). Collaborative similarity embedding for recommender systems. World wide web conference (pp. 2637- 2643).
- [3] Chen, C. M., Wang, T. H., Wang, C. J., & Tsai, M. F. (2019, September). SMORE: modularize graph embedding for recommendation. In Proceedings of the 13th ACM Conference on Recommender Systems (pp. 582-583).
- [4] Lemire, D., & Maclachlan, A. (2005, April). Slope one predictors for online rating-based collaborative filtering. In Proceedings of the 2005 SIAM International Conference on Data Mining (pp. 471-475). Society for Industrial and Applied Mathematics.
- [5] Yu, L., Zhang, C., Pei, S., Sun, G., Zhang, X. (2018). Walkranker: A unified pairwise ranking model with multiple relations for item recommendation.
- [6] Sepulveda, G., Dominguez, V., & Parra, D. (2017). pyreclab: A software library for quick prototyping of recommender systems. arXiv preprint arXiv:1706.06291.
- [7] Rendle, S., Freudenthaler, C., Gantner, Z., & Schmidt-Thieme, L. (2012). BPR: Bayesian personalized ranking from implicit feedback. arXiv preprint arXiv:1205.2618.
- [8] Hu, Y., Koren, Y., & Volinsky, C. (2008, December). Collaborative filtering for implicit feedback datasets. In 2008 Eighth IEEE International Conference on Data Mining (pp. 263-272). Ieee.

- [9] S. Funk. Funk SVD. (2006). Try this at home. Blog post: <http://sifter.org/~simon/journal/20061211.html>. December11.
- [10] Lemire, D., & Maclachlan, A. (2005, April). Slope one predictors for online rating-based collaborative filtering. In Proceedings of the 2005 SIAM International Conference on Data Mining (pp. 471-475). Society for Industrial and Applied Mathematics.
- [11] Lerche, L., Jannach, D. (2014, October). Using graded implicit feedback for bayesian personalized ranking. In Proceedings of the 8th ACM Conference on Recommender systems (pp. 353-356).
- [12] Vinh Tran, L., Nguyen Pham, T. A., Tay, Y., Liu, Y., Cong, G., Li, X. (2019, July). Interact and decide: Medley of sub-attention networks for effective group recommendation. In Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (pp. 255-264).
- [13] Cao, D., He, X., Miao, L., An, Y., Yang, C., Hong, R. (2018, June). Attentive group recommendation. In The 41st International ACM SIGIR Conference on Research Development in Information Retrieval (pp. 645-654).
- [14] Cao, D., He, X., Miao, L., Xiao, G., Chen, H., Xu, J. (2019). Social-enhanced attentive group recommendation. IEEE Transactions on Knowledge and Data Engineering.
- [15] Hu, L., Cao, J., Xu, G., Cao, L., Gu, Z., Cao, W. (2014, July). Deep Modeling of Group Preferences for Group-Based Recommendation. In AAAI (Vol. 14, pp. 1861-1867).