

Sistema de Recomendación Secuencial de Items para juegos MOBA

Yesenia Salinas

Pontificia Universidad Católica de Chile

Santiago, Chile

yhsalinas@uc.cl

ABSTRACT

Actualmente, en el mundo de los video juegos, el género MOBA se ha convertido en un gran representante de los eSports. Los juegos dentro del género se caracterizan por ser estratégicos y múltiples jugadores. Dentro del juego, cada jugador elige un personaje e ítems con los que jugará durante una partida, en la mayoría de veces, la elección de esos ítems se basa en el historial de compras hechas hasta un momento de la siguiente compra. Los sistemas de recomendación tienen un rol importante cuando se trata de recomendar ítems e incluso personajes. Este trabajo propone un sistema de recomendación que se basa en la secuencia de compras de ítems dado un jugador. El modelo evalúa la recomendación según el historial de compras, donde cada compra esta dada en un momento determinado. Construimos el algoritmo en base a Gated Recurrent Unit (GRU) para recomendaciones; donde se obtuvo 60% de recall con el dataset de test.

Author Keywords

- sistema recomendador, - redes neuronales, - dota

1. INTRODUCCIÓN

Los videojuegos multijugadores en línea son híbridos de juegos de acción, juegos de roles y juegos de estrategia en tiempo real (RTS) [4]. En particular, uno de los juegos más conocidos de este tipo es Dota; el cual es uno de los más populares en el mundo de MOBA. En el juego participan dos equipos *Radiant* y *Dire*, cada equipo con 5 jugadores, y el ganador de una partida es uno de los equipos mencionados con sus jugadores. Para una partida cada jugador elige a un *Héroe*; con el cual jugará toda la partida, y además compra un conjunto de ítems para comenzar el juego. Durante una partida un jugador puede comprar ítems, los cuales le sirven para vencer al oponente. Entonces, la compra de cada ítem es una decisión muy importante, y muchas veces esa decisión depende del momento en el que se encuentre la partida. De esta manera, a la hora

de comprar de ítems es muy importante tomar en cuenta el tiempo, es decir, la secuencia de compras.

Los sistemas recomendadores abordan diferentes problemáticas a la hora de la elección de compra de un ítem, e incluso para la elección del hero/campeón. El juego de Dota contiene 112 heros para elegir, y 189 ítems en total. Así, existen muchas posibles combinaciones de los heros con los ítems, por lo que la decisión de la compra de ítems es muy importante.

Las recomendaciones que podría generar un modelo recomendador podrían ser al inicio de una partida, o a cada cierto momento de la partida. En este último, hablamos de una recomendación secuencial, la cual podría llegar a ser más útil al jugador, ya que en promedio un jugador tiene 30 segundos para comprar ítems. De ese modo, recomendar ítems durante toda la partida ayudaría a: i) comprar los mejores ítems en el tiempo dado y ii) dado un ítem recomendado, este incrementa la probabilidad de ganar puntos y en sí, ganar la partida.

El trabajo actual presenta una solución a la recomendación secuencial de ítems para el juego Dota. Entonces, dada la problemática descrita anteriormente, el modelo que presentamos toma en cuenta las compras de un jugador en un tiempo t_i , y el hero h_k elegido por el jugador. Para lograr el objetivo planteado recolectamos los datos de partidas reales; las cuales contienen el historial de compras de ítems con su respectivo tiempo. El algoritmo diseñado tiene la arquitectura de un modelo de aprendizaje profundo, el cual es una Gated recurrent unit (GRU) aplicada a sistemas recomendadores.

La estructura del artículo es la siguiente: Sección 2 describe los aportes relacionados en términos de recomendación para juegos MOBA, y trabajamos en cuanto a sistemas recomendadores secuenciales para compras de ítems. La Sección 3 la metodología planteada para la problemática. Los resultados y evaluación del modelo se presentan en la Sección 4. Finalmente, presentamos una breve discusión y conclusiones sobre el trabajo en la sección 5.

2. TRABAJOS RELACIONADOS

Durante los últimos años han surgido muchos enfoques diferentes para resolver el problema de incrementar la probabilidad y eficiencia de que un equipo en el juego multijugador en línea DOTA 2. Los sistemas recomendadores fueron uno de los enfoques explorados para incrementar dicha probabilidad. Uno de los trabajos con mayor acercamiento a la recomendación de

ítems es de [1]; quienes aplican algoritmos de minería de datos y redes neuronales para la recomendación de ítems para un jugador al inicio de una partida. Como ampliación a este modelo, el trabajo de [6] aborda la problemática de recomendación de ítems, incluyendo el contexto. En ese sentido, [6] toma en cuenta los roles de los jugadores. [4] propone un trabajo donde a comparación de los anteriores aportes, este implementa técnicas de regresión y clustering para la recomendación de ítems. Una aplicación de inteligencia de máquina para la elección de héroes en el juego Dota fue de [5], quienes predicen el la probabilidad de ganar una partida de dota, dado los héroes de un equipo. Así, notamos la gran importancia que tiene la elección de los héroes, pero sobretudo la elección de ítems frente a cada momento de una partida. De esta manera, la recomendación secuencial se exploró en gran parte para e-commerce [2]. A su vez, un trabajo de [3] propone una arquitectura GRU para la recomendación de ítems basada en sesiones. Además, ellos incorporan la información histórica de compras de los usuarios, solo que aplicada a e-commerce.

3. METODOLOGÍA

El problema de la presente investigación es construir un algoritmo efectivo para recomendar ítems a un jugador a medida que transcurra una partida. Esta recomendación es basada en información sobre los héroes de DOTA 2 elegidos por los jugadores, además de los ítems que tenga en su historial de compras, es decir los ítems en tiempo t_{i-1} . En inicio se toman los datos de los equipo "radiant" o "dire", dependiendo quién haya ganado la partida.

3.1. Preprocesamiento de Datos

El dataset corresponde a 50k partidas de Dota 2; el cual se encuentra en Kaggle ¹. En total, el dataset contiene 13 archivos, de los cuales y según la exploración de los datos, para el proyecto utilizamos 6 archivos. Primeramente, enumeramos y describimos a cada archivo:

1. **item_ids**: Contiene un diccionario de todos los ítems, el cual incluye el nombre y su identificador. En total son 189 ítems.
2. **hero_names**: Contiene un diccionario de todos los héroes, el cual incluye el nombre y su identificador. En total son 112 héroes.
3. **match_path**: Contiene un pequeño detalle las partidas, el detalle incluye al tiempo de inicio, duración de la partida, además indica el equipo ganador de la partida. En total son 50k partidas.
4. **players**: En el archivo se encuentran los detalles de 500k players. Entre los atributos más importantes, y que se utilizan para la solución de la propuesta se encuentran la partida que jugaron, el hero con el que jugaron, la posición, y algunos detalles del oro que tiene. Es importante notar que, un jugador puede tener una misma cuenta para varias partidas, es decir, tomamos a los jugadores independientemente de sus cuentas de usuario.

¹https://www.kaggle.com/devinanzelmo/dota-2-matches?select=purchase_log.csv

Table 1.

Descripción	Valor Min	Valor Max
Tiempo de compra de un ítem	-90	25914 seg.
Duración de la partida	59	34037 seg.
Partidas ganadas por "radiant"	25943	25943
Partidas ganadas por "dire"	24057	24057
Ítems comprados por partida	0.95	3098




Figure 1. Compra de un ítem en un momento t_i de la partida

5. **player_time**: Los atributos que nos interesan tienen la información del oro con relación al tiempo que posee un jugador, eso para diferentes partidas.
6. **purchase_log**: Es uno de los archivos más importantes para considerar, ya que contiene información que necesitamos para obtener el tiempo de compra de diferentes ítems con respecto a los jugadores en sus respectivas partidas.

Se tomaron en cuenta las 50k partidas, en cada partida participan 2 equipos; los cuales son "radiant" y "dire". Tomamos en cuenta ambos equipos, y clasificamos las partidas ganadas y perdidas por cada uno. Cada partida las relacionamos con los jugadores, el historial de compras de ítems, y los héroes con los que jugó cada player.

Durante el análisis del tiempo y duración de las partidas para construir la secuencia de compras con relación a las compras de los oponentes notamos que, las combinaciones de compras eran demasiadas. En ese sentido, no se pudo trabajar con los datos completos de la relación de jugador con su héroe y los ítems comprados por los oponentes. La Tabla 1 muestra el detalle sobre los parámetros mencionados; el cual notamos que existen partidas de muy poca duración, con una gran diferencia de la partida con mayor duración. Podemos mostrar que tenemos un dataset con gran cantidad de variación en el tiempo de duración, como en la cantidad de compras en una partida. En ese sentido, las combinaciones se extienden a gran escala, por lo que decidimos trabajar únicamente con el historial de compras de un jugador,

Para contruir la entrada al modelo propuesto, tomamos el héroe y sus compras. La Figura 1 muestra la arquitectura de la secuencia que se contruyó para el modelo recomendador.

3.2. Modelo de Recomendación

El modelo que se trabajó fue RNN basado en GRU [2][3] (Ver Figura 2). La entrada del modelo son las compras de un jugador con sus respectivo tiempo de compra. Para entrada del modelo se filtraron los ítems no consumibles, además se trabajó con únicamente los jugadores ganadores. Para una mejor representatividad para el modelo, la entrada son los héroes e ítems como one-hot. El entrenamiento del modelo se realiza tomando un el héroe de un jugador y diferentes sets de compras, es decir ítems I_1, \dots, I_i donde el set test viene a ser I_{i+1}, \dots, I_n . Para la predicción, se calcula el score para




Figure 2. Arquitectura general de la red. Imagen de [8]

un número pequeño de ítems, es decir un subconjunto. Esto también implica que solo se actualizarán algunas de las ponderaciones. Esto hace la suposición de que cuanto más popular sea el ítem, es decir, que el ítem haya sido comprado con frecuencia por jugadores en otras partidas, la probabilidad de que un jugador diferente lo sepa se incrementa, y así el modelo le recomiende un determinado ítem. De este modo, el modelo utiliza los ítems de los otros samples del dataset de entrenamiento del mini-lote. La idea de fondo es que se reduzcan los tiempos de muestreo para el entrenamiento, ya que, como se mencionó anteriormente, el dataset contiene muchas combinaciones posibles de compra de ítems.

4. EVALUACIÓN Y RESULTADOS

Dado un jugador y las compras que realizó, el modelo recomienda la siguiente compra, tomando en cuenta el tiempo en el que se encuentra de la partida. La Tabla 5 muestra los resultados de la arquitectura GRU en comparación con la arquitectura de [1]. Claramente la arquitectura de GRU muestra una mejora significativa, además de que la recomendación de los ítems no es solo para el inicio de la partida, sino que es dependiendo a un momento específico del juego. El resultado que mostramos en la tabla anterior muestra los mejores resultados obtenidos. Entre los experimentos realizados se hicieron combinaciones entre 100 y 500 hidden units de la red. El tipo de optimización de la arquitectura final es de Adagrad, con una tasa de aprendizaje de 0.001. El tiempo de entrenamiento básicamente dependía de la parametrización del modelo, y sobre todo la cantidad de datos que esten siendo entrenados.

5. DISCUSIÓN Y CONCLUSIONES

Como ya se mencionó antes, la comunidad de jugadores en MOBA incrementa cada vez, por lo que realizar una recomendación de ítems basado en datos de partidas de expertos llegó a tener buenos resultados. En ese sentido, la propuesta de la recomendación secuencial es de gran relevancia, eso debido a la cantidad tan variada de compras que realizan los jugadores en una sola partida. El trabajo actual presenta un modelo de recomendación secuencial para el juego de Dota, el cual es basado en la arquitectura de GRU. Sin embargo, para la construcción de dicha arquitectura no se tomó en cuenta la información de compras de los oponentes, sino únicamente el historial de compras del héroe/campeón. De esta manera, como trabajo futuro planteamos incorporar dicha información,

Modelo	MRR	Recall	Precision
ANN	0.303	0.483	0.436
GRU	0.379	0.591	0.583

Table 2. Table caption

así incrementaríamos la probabilidad de ganar una partida escogiendo los mejores ítems dependiendo a todo el equipo oponente.

REFERENCES

- [1] Vladimir Araujo, Felipe Rios, and Denis Parra. 2019. Data mining for item recommendation in MOBA games. In *Proceedings of the 13th ACM Conference on Recommender Systems*. 393–397.
- [2] Raj Bhatta, CI Ezeife, and Mahreen Nasir Butt. 2019. Mining Sequential Patterns of Historical Purchases for E-commerce Recommendation. In *International Conference on Big Data Analytics and Knowledge Discovery*. Springer, 57–72.
- [3] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. 2015. Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939* (2015).
- [4] Wenli Looi, Manmeet Dhaliwal, Reda Alhajj, and Jon Rokne. 2018. Recommender system for items in dota 2. *IEEE Transactions on Games* (2018).
- [5] Iuliia Porokhnenko, Petr Polezhaev, and Alexander Shukhman. 2019. Machine Learning Approaches to Choose Heroes in Dota 2. In *2019 24th Conference of Open Innovations Association (FRUCT)*. IEEE, 345–350.
- [6] Andrés Villa, Vladimir Araujo, Francisca Cattán, and Denis Parra. 2020. Interpretable Contextual Team-aware Item Recommendation: Application in Multiplayer Online Battle Arena Games. In *Fourteenth ACM Conference on Recommender Systems*. 503–508.